Eddy Michel ELLA MINTSA

Statut: Attaché de recherche à l'Institut de Recherche Technologique (IRT), CENAREST

Contact

Adresse professionnelle: B.P.14070, Libreville, Gabon

Téléphone portable: +241 65 44 54 46

Email personnel: `eddymichlellamintsa@yahoo.fr`

Page personnelle: `http://www.eddyellamintsa.com`

Informations personnelles

Date et lieu de naissance: 29/10/1992 à Oyem

Nationalité: gabonaise

État civil: marié

Titre: Docteur en mathématiques appliquées, Université Gustave Eiffel, France

Qualifié par le CNU section 26

Situation actuelle

Attaché de recherche, Institut de Recherche Technologique (IRT), Centre National de la Recherche Scientifique et Technologique (CENAREST)

Thèmes de recherche

- Apprentissage statistique
- Données fonctionnelles
- Estimation non-paramétrique
- Statitsique des processus
- Théorie minimax

Expérience professionnelle

[2024 - 2025] **Maître de conférences contractuel** MIA Paris-Saclay, AgroParisTech

[2023 - 2024] **Maître de conférences contractuel** LAMA, Université Gustave Eiffel, France

[2020 - 2023] **Allocataire de recherche** LAMA, Université Gustave Eiffel, France
Monitorat, 64 heures / an

[2020] **Stage de recherche master 2 (5 mois)** LAMA, Université Gustave Eiffel, France
Le stage est basé sur l'article *"Consistent procedures for multiclass classification of discrete diffusion paths"*, C. Denis, C. Dion et M. Martinez (2020), *Scandinavian Journal of Statistics* **47**, 516-554
Encadrants: Christophe Denis et Charlotte Dion

[2019] **Projet de master 1 (3 mois)** Université Paris-Est Marne-la-Vallée
*"Visualisation et classification des données numériques multidimensionnelles"*application aux données internationales d'immigration (avec `R`)
Encadrante: Claire Lacour

Formation

[2020 - 2023] **Doctorat en mathématiques appliquées** LAMA, Université Gustave Eiffel, France
"Classification supervisée et estimation non-paramétrique pour les Equations Différentielles Stochastiques (EDS)"
Sous la co-direction de
Christophe Denis (Co-directeur, Université Gustave Eiffel),
Charlotte Dion-Blanc (Co-directrice, Sorbonne Université),
Viet-Chi Tran (Directeur, Université Gustave Eiffel)
Soutenue le 12 décembre 2023 devant le jury composé de
Marc Hoffmann (Président, Université Paris-Dauphine),
Dasha Loukianova (Rapportrice, Université d'Evry Val d'Essonne),
Clément Marteau (Rapporteur, Université Lyon 1),
Claire Lacour (Examinatrice, Université Gustave Eiffel),
Arnak Dalalyan (Examinateur, ENSAE Paris).

[2019 - 2020] **Master 2 Mathématiques et Applications** Université Gustave Eiffel, France
Parcours Probabilités et Statistiques de nouvelles données
Mention bien

[2018 - 2019] **Master 1 Mathématiques et Applications** Université Paris-Est Marne-la-Vallée, France
Mention très bien

[2017 - 2018] **Master 1 MEEF 2nd degré Mathématiques** Université Paris-Est Marne-le-Vallée
Mention bien

[2015 - 2017] **Master 1 Actuariat** ISFA, Université Lyon 1, France

[2014 - 2015] **Licence 3 Sciences Financière et d'Assurances** ISFA, Université Lyon 1, France

[2012 - 2014] **Math Sup - Math Spé, MPSI - MP** Lycée National Léon Mba

[2012] **Baccalauréat, Série C** Lycée de l'Excellence d'Oyem

Exposé des activités d'enseignement

Je totalise un volume horaire d'environ 600 heures (équivalent TD) en enseignement. Plus précisément, j'ai assuré plus 200 heures de cours/ Travaux Dirigés (TD)/Travaux Pratiques (TP) entre 2024 et 2025 comme Maitre de conférences contractuel à AgroParisTech, 192 heures de cours/TD/TP entre 2023 et 2024 comme Attaché Temporaire d'Enseignement et de Recherche à l'Université Gustave Eiffel, puis 192 heures de cours/TD comme doctorant contratuel à l'Université Gustave Eiffel entre 2020 et 2023.
J'ai été amené à construire mes propres cours, TD et TP, en statistique, probabilités et mathématiques, contribuer à la construction de sujets de contrôles continus et d'examens.
J'ai dispensé des cours, animé des séances de TD et TP dans tous les niveaux des cycles Licence et Master, et à des publics variés. Je bénéficie ainsi d'une bonne capacité d'adaptation aux étudiants de divers parcours et spécialités.

[2024 - 2025] **Master 2 Économie et Gestion d'Entreprise (EGE)** AgroParisTech
Statistique, Cours/TP, 24.5h
Programme: Statistiques descriptives, Analyse en Composantes Principales (ACP), Régression linéaire multiple, Analyse de la variance (ANOVA), Analyse de la covariance (ANCOVA), Régression logistique, TP avec le logiciel `R`.

[2024 - 2025] **Master 2 Biodiversité, Écologie et Évolution (BEE)** AgroParisTech
Statistique, TP, 9h
Programme: Régression linéaire, ANOVA, ACP, TP avec le logiciel `R`.

[2024 - 2025] **Master 2 Évolution des Génômes, des Populations et des Espèces (EvoGEM)** Université Paris-Saclay
Probabilités, Cours (3.5h), TD (3.5h)
Programme: Chaines de Markov à espace de temps discret (TP), Processus de Poisson (Cours).

[2024 - 2025] **Master 2 Biologie et biotechnologie pour la santé et les productions microbiennes ou végétales (GIPE)** AgroParisTech
Séries temporelles, Cours (3h), TP (9h)
Programme: Stationnarité, Modélisation des séries chronologiques, Processus ARMA, Cas pratiques avec le logiciel `R`.

[2024-2025] **Master 2 Dominante De l'Information à la Décision par l'Analyse et l'Apprentissage (IODAA)** AgroParisTech
Statistique en grande dimension, TP, 9h
Programme: Régressions Ridge, LASSO et Elastic-Net, Abre de décision, Bagging, Forêt aléatoire, Boosting, Régression logistique, Méthode des plus proches voisins (régression et classification), TP avec le logiciel `R`.

[2024 - 2025] **Master 1 Science de l'Ingénieur et Modélisation Mathématique (SIMM)** AgroParisTech
Statistique, CM (6h), TD (12h), TP (12h)
Programme: ACP, Classification non-supervisée (méthode des Kmeans), Classification Ascendante Hiérarchique (CAH), Régression linéaire multiple, ANOVA, ANCOVA, Régression logistique, Méthode des plus proches voisins (régression et classification), TP avec le logiciel `R`.

Passerelle (AST): Estimation ponctuelle, Estimation par intervalle de confiance, tests statistiques.

[2024 - 2025] **Master 1 Science de l'Ingénieur et Modélisation Mathématique (SIMM)** AgroParisTech
Statistiques pour la santé (D4-UC), TP (9h)
Programme: Modèle Linéaire Généralisé (GLM), Modèles de survie, Modèles statistiques non-linéaires, TP avec le logiciel `R`.

[2024-2025] **Master 1 Science de l'Ingénieur et Modélisation Mathématique (SIMM)** AgroParisTech
Topologie (UC1), Cours (3h)
Programme: Normes, Ouverts, Fermés, Complétude, Compacité, Théorème du point fixe.

[2024-2025] **Master 1 Science de l'Ingénieur et Modélisation Mathématique (SIMM)** AgroParisTech
Ingénierie par la simulation numérique (UC Projet), Cours (3h), TP (3h)
Programme: Processus stochastique, Mouvement Brownien, Equation différentielle stochastique (EDS), Simulation d'une EDS par le schéma d'Euler et le schéma de Milstein, TP avec le logiciel `R`.

[2023 - 2024] **Licence 3 Maths - MIASH** Université Gustave Eiffel
Statistique, TD/TP, 36h
Programme: Statistiques descriptives, Estimation paramétrique (estimateur des moments, estimateur du maximum de vraisemblance, information de Fisher, intervalle de confiance, efficacité), Vecteurs gaussiens, TP avec `R`.

[2023 - 2024] **Licence 2 Économie et Gestion** Université Gustave Eiffel
Probabilités, TD/TP, 49.5h
Programme: Lois classiques (loi normale, loi du Khi-2, loi de Student), Distributions d'échantillonnage, Convergence de variables aléatoires, Estimation ponctuelle.

[2023 - 2024] **Licence 1 Économie et Gestion** Université Gustave Eiffel
Mathématiques, TD, 36h
Programme: Rappels sur les limites de fonctions, Comparaisons de fonctions, Développements limités, Intégration, Suites.

[2023 - 2024] **Licence 1 Économie et Gestion** Université Gustave Eiffel
Statistique, TD, 69h
Programme: Variables aléatoires discrètes sur un espace probabilisé fini, Lois discrètes (loi uniforme, loi de Bernoulli, loi binomiale, loi géométrique, loi de Poisson), Lois continues (loi uniforme, loi exponentielle, loi normale).

[2020 - 2023] **Licence 1 Physique - Chimie** Université Gustave Eiffel
Calculus, Cours/TD, 64h/an
Programme: Nombres complexes, Généralités sur les fonctions, Fonctions bijectives, Développements limités, Intégration, Équations différentielles linéaires.

[2023] **Encadrement du Hackathon** Université Gustave Eiffel
Sujet proposé par l'entreprise Scor sur l'évaluation de la probabilité de blessure d'un joueur sur une période de 30 jours.

[2022] **Encadrement du Hackathon** Université Gustave Eiffel
Sujet proposé par l'entreprise Scor sur la prédiction de rémission de cancer

Activité de recherche

Publications

[1] **"Nonparametric plug-in classifier for multiclass classification of S.D.E. paths"** C. Denis, C. Dion, E. Ella-Mintsa, V.-C. Tran
Scandinavian Journal of Statistics (2024)
Lien vers l'article: `http://doi.org/10.1111/sjos.12702`

[2] **"Nonparametric estimation of the diffusion coefficient from i.i.d. S.D.E. paths"** E. Ella-Mintsa
Statistical Inference for Stochastic Processes (2024)
Lien vers l'article:
`https://link.springer.com/article/10.1007/s11203-024-09310-9`

[3] **"Minimax rates of convergence for the nonparametric estimation of the diffusion coefficient from time-homogeneous SDE paths"** E.-M. Ella-Mintsa
Statistical Inference for Stochastic Processes
Liens vers l'article: `https://www.doi.org/10.1007/s11203-025-09335-8`

Soumissions

[1] **"Rates of convergence of a binary classification procedure for time-homogeneous S.D.E paths"** E.-M. Ella-Mintsa
Metrika (en révision)
Liens ArXiv: `https://arxiv.org/pdf/2501.15926`

[2] **"Empirical risk minimization algorithm for multiclass classification of S.D.E. paths"** C. Denis, E.-M. Ella-Mintsa
Lien HAL: `https://hal.science/hal-04994403/`
Liens ArXiv: `https://arxiv.org/pdf/2501.15933`

[1] **"Minimax convergence rates of a binary plug-in type classification procedure for time-homogeneous SDE paths under low-noise conditions"** E.-M. Ella-Mintsa
Lien ArXiv: `https://arxiv.org/pdf/2603.00827`

Travaux en cours

[1] **"Optimal classification of trajectories from stochastic eifferential equations"** C. Denis, E.-M. Ella-Mintsa, Alberto Suárez

[2] **"An adaptive wavelet particle approximation for statistical solution of McKean-Vlasov equations"** E.-M. Ella-Mintsa, H.-V. Hà, V.-C. Tran

Communications orales

Conférences

- The StatMathAppli conference (2022)
- The Dynstoch meeting (2022)

- 5th International Workshop on Functional and Operational Statistics (IWFOS 2021)
- 54èmes Journées de Statistique de la Société Française de Statistique (SFdS) (JDS 2023)
- 9èmes Rencontres des Jeunes Statisticiens (RJS 2022)
- 53èmes Journées de Statistique de la Société Française de Statistique (SFdS) (JDS 2022)

Séminaires

- Séminaire Modal'X à l'Université Paris Nanterre (2025)
- Séminaire MIA Paris-Saclay, AgroParisTech (2024)
- Séminaire Parisien de Statistiques à l'Institut Henri Poincaré (IHP) (2023)
- Groupe de Travail des Thesards (GTT) du LPSM de Sorbonne Université (2022)

Langues et outils informatiques

Français, Fang: langues maternelles

Anglais: niveau intermédaire avancé (Lu, Écrit, Parlé)

Programmation en `R`: Dans ma thèse, d'importants codes de simulation sont developpés en `R`, aboutissant à la création d'un package pour la classification des trajectoires de diffusions.

- **Package R** SDEclassif: `https://github.com/Eddymichelella/SDEclassif.git`

Programmation en Python

Divers

Professeur particulier de mathématiques via Acadomia et Complétude pour les publics suivants:

- Élèves de lycée (2nde, 1ère, Terminale)
- Élèves des Classes Préparatoires aux Grandes Écoles (CPGE):
  - Première année Mathématiques, Physique et Sicence de l'Ingénieur (MPSI)
  - Deuxième année Physique-Chimie (PC*)
  - Deuxième année Physique et Technologie (PT)

1 Exposé des activités de recherche

Mes travaux de recherche portent sur l'étude statistique des données fonctionnelles, particulièrement celles modélisées par des équations différentielles stochastiques (EDS). Il s'agit plus précisément de la classification des trajectoires de diffusion et de l'inférence statistique sur les coefficients de dérive et de diffusion d'une EDS. La classification des trajectoires est un domaine important de recherche en statistique, les récentes avancées technologiques facilitant la collecte de ce type de données (voir Ramsay & Silverman (2002), Ramsay & Silverman (2005)). Ces nouvelles données trouvent des applications dans de nombreux domaines; citons par exemple la dynamique de la vitesse cellulaire en biologie (voir Romanczuk *et al.* (2012)), ou encore la finance avec la modélisation du prix d'un actif financier (voir Lamberton & Lapeyre (2011)). Cette problématique s'inscrit dans le cadre général de la classification de données fonctionnelles. Dans ce contexte, des méthodes générales on été étudiées (voir Biau *et al.* (2005), López-Pintado & Romo (2006), Cuevas *et al.* (2007)). Alors qu'une littérature importante s'est developpée pour l'estimation paramétrique et non-paramétrique des coefficients de dérive et de diffusion d'une EDS, peu de travaux étudient la classification pour le cas des données modélisées par des processus de diffusion (voir Cadre (2013), Gadat *et al.* (2020), Denis *et al.* (2020)). La mise en place d'une procédure de classification adaptée à ce type de modèle est un enjeu majeur. Tout en suivant des schémas relativement naturels, de nombreuses difficultés émergent, et pour y répondre, il faudra combiner calcul stochastique avancé et théorie de l'apprentissage.

1.1 Présentation générale du problème

Nous nous plaçons dans le cadre de la classification multi-classes avec $K \geq 2$ le nombre de classes, et nous considérons le modèle de mélange de processus de diffusion observés sur l'intervalle de temps $[0, T]$ suivant:

$$dX_t = b_Y^*(X_t)dt + \sigma^*(X_t)dW_t, \quad X_0 = x_0$$

où $(W_t)_{t\geq 0}$ est un mouvement Brownien standard et tel que l'étiquette $Y \in \mathcal{Y} = \{1, \ldots, K\}$ est indépendante de $(W_t)_{t\geq 0}$ de loi inconnue donnée par $\mathfrak{p}^* = (\mathfrak{p}_1^*, \ldots, \mathfrak{p}_K^*)$. On pose $T = 1$, et on note $\mathcal{X}$ l'ensemble des processus de diffusion observés dans l'intervalle de temps $[0, 1]$. Un classifieur (ou règle de classification) g est une fonction mesurable sur $\mathcal{X}$ et à valeurs dans $\{1, \ldots, K\}$, qui prend en argument une trajectoire $X \in \mathcal{X}$ dont la vraie étiquete (ou classe) est Y, et prédit sa classe $g(X)$. La performance du classifieur g est évaluée au moyen de la mesure de performance $\mathcal{R}$ appelée risque de classification:

$$\mathcal{R}(g) = \mathbb{P}_{X,Y}(g(X) \neq Y).$$

On appelle classifieur de Bayes, le classifieur g^* qui minimise le risque de classification. Soit $\mathcal{G}$ un ensemble de classifieurs. On a

$$g^* \in \arg\min_{g\in\mathcal{G}} \mathcal{R}(g).$$

Le classifieur g^* est caractérisé pour tout $X \in \mathcal{X}$ par

$$g^*(X) = \arg\max_{i\in\mathcal{Y}} \pi_i^*(X), \quad \text{avec} \quad \pi_i^*(X) = \mathbb{P}_{X,Y}(Y = i|X).$$

Le résultat suivant est établi dans Denis *et al.* (2020):

$$\forall\ i \in \mathcal{Y}, \quad \pi_i^*(X) = \phi_i^*(\mathbf{F}^*(X)) \quad \mathbb{P}_{X,Y} - p.s.$$

où $\mathbf{F}^*(X) = (F_1^*(X), \ldots, F_K^*(X))$, avec pour chaque $i \in \mathcal{Y}$,

$$F_i^*(X) := \int_0^1 \frac{b_i^*}{\sigma^{*2}}(X_s)dX_s - \frac{1}{2}\int_0^1 \frac{b_i^{*2}}{\sigma^{*2}}(X_s)ds, \quad \phi_i^* : (x_1, \ldots, x_K) \mapsto \frac{\mathfrak{p}_i^* \mathrm{e}^{x_i}}{\sum_{j=1}^K \mathfrak{p}_j^* \mathrm{e}^{x_j}}.$$

Le classifieur de Bayes g^* n'est malheuresement pas calculable, car il dépend des paramètres inconnus $\mathbf{b}^* = (b_1^*, \ldots, b_K^*)$, σ^{*2} et $\mathfrak{p}^* = (\mathfrak{p}_1^*, \ldots, \mathfrak{p}_K^*)$. Considérons un échantillon d'apprentissage $\mathcal{D}_N = \left(\bar{X}^j, Y_j\right)_{j=1,\ldots,N}$ constitué de N copies indépendantes du couple $(\bar{X}, Y)$ avec $\bar{X} = (X_{k\Delta_n})_{0\leq k\leq n}$, $\Delta_n = 1/n$ et $n \to \infty$. On construit ainsi à partir de $\mathcal{D}_N$, une procédure de classification multi-classes $\widehat{g}$ qui imite le classifieur de Bayes et telle que

$$\mathbb{E}_{X,Y}\left[\mathcal{R}(\widehat{g}) - \mathcal{R}(g^*)\right] \to 0 \ \text{ lorsque } \ N, n \to \infty.$$

Deux types de procédures de classification empiriques sont proposés. Le premier classifieur empirique de type *plug-in* (section 1.4) est basé sur l'estimation non-paramétrique des fonctions $\mathbf{b}^*$ et σ^{*2} (sections 1.2 et 1.3), et le deuxième classifieur (type ERM) est construit par minimisation du risque empirique (section 1.5). Pour la première approche, j'ai proposé des nouveaux estimateurs du coefficient de diffusion (dépendant de l'espace) sur un support non-compact, les observations étant générées par des processus de diffusion non-bornés. La construction de ces estimateurs prend en compte divers schémas d'observations.

1.2 Estimation non-paramétrique du coefficient de diffusion

Ce travail a donné lieu à deux articles dont un premier publié en 2024, et un deuxième actuellement en révision à Statistical Inférence for Stochastic Processes. Le carré du coefficient de diffusion σ^{*2} est estimé par projection sur un espace de dimension finie, à partir de l'échantillon de données $\mathcal{D}_N$, comme solution du modèle de regression suivant

$$\frac{(X_{(k+1)\Delta_n} - X_{k\Delta_n})^2}{\Delta_n} = \sigma^{*2}(X_{k\Delta}) + \zeta_{k\Delta}, \qquad k = 0, \ldots, n-1$$

avec $\zeta_{k\Delta_n}$ le terme d'erreur. L'estimateur $\widehat{\sigma}^2$ de σ^{*2} est construit par minimisation d'une fonction de contraste des moindres carrés. On propose des estimateurs sur un intervalle compact et sur la droite réelle en distinguant les cas $N = 1,\ n \to \infty$ et $n, N \to \infty$. On établit la consistance des estimateurs et les vitesses suivantes sur un espace Hölder de paramètre de régularité $\beta \geq 1$.

1. Pour le cas d'une seule observation ($N = 1,\ n \to \infty$):
   - Vitesse optimale de l'ordre de $n^{-\beta/(2\beta+1)}$ sur un intervalle compact,
   - Vitesse de l'ordre de $n^{-\beta/(4\beta+1)}$ sur la droite réelle $\mathbb{R}$.
2. Pour le cas d'observations répétées ($n, N \to \infty$):
   - Vitesse optimale de l'ordre de $(Nn)^{-\beta/(2\beta+1)}$ sur un intervalle compact,
   - Vitesse de l'ordre de $(Nn)^{-\beta/(4\beta+1)}$ sur la droite réelle $\mathbb{R}$ avec $n \geq N$,
   - Vitesse optimale de l'ordre de $(Nn)^{-\beta/(2\beta+1)}$ sur un intervalle de la forme $[-A_N, A_N]$ avec $A_N > 0$ choisi tel que $A_N \to \infty$ lorsque $N \to \infty$.

Les résultats établis sur la droite réelle $\mathbb{R}$ et l'intervalle $[-A_N, A_N]$ constituent la principale contribution de ce travail sur l'inférence statistique du coefficient de diffusion d'une équation différentielle stochastique à horizon temporel fini ($T < \infty$). L'optimalité de la vitesse de l'ordre de $n^{-\beta/(2\beta+1)}$ établie sur un intervalle compact pour le cas $N = 1$, est prouvée dans Hoffmann (1999). L'estimateur proposé dans ce travail est plus facilement implémentable avec sélection de modèle à partir des données. Pour le cas $n, N \to \infty$, la vitesse de l'ordre de $(Nn)^{-\beta/(2\beta+1)}$ est une nouveauté sur le plan théorique, car il n'est pas aisé d'établir une vitesse du même ordre à partir de celles obtenues dans la littérature.

Des estimateurs adaptatifs sont proposés pour le cas compact ($N = 1$ et $N \to \infty$), et le cas non-compact ($N \to \infty$).

1.3 Estimation non-paramétrique des fonctions de dérive

Nous utilisons l'estimateur par projection de la fonction de dérive proposé dans Denis *et al.* (2021), et nous obtenons de la borne de risque qu'ils établissent lorsque le drift est estimé sur $\mathbb{R}$, une vitesse de l'ordre de $N^{-1/5}$ lorsque les fonctions estimées sont supposées appartenir à un espace de fonctions lipschitziennes. Dans Denis *et al.* (2021), une vitesse optimale de l'ordre de $N^{-\beta/(2\beta+1)}$ est établie sur l'intervalle compact $[0,1]$, $\beta \geq 1$ étant le paramètre de régularité d'un espace de type Hölder. La principale contribution de notre travail est d'établir une vitesse du même ordre (à un facteur logarithmique près) sur la droite réelle $\mathbb{R}$ sans troncature de la dimension du sous-espace d'approximation. Pour cela, nous reprenons la méthode développée dans Comte & Genon-Catalot (2020) pour contourner le problème posé par la non-compacité du support de la fonction de dérive estimée. De plus, la fonction de dérive étant construite sur un intervalle compact $[-A_N, A_N]$ avec A_N qui tend vers l'infini lorsque N tend vers l'infini, des estimations plus fines des probabilités de sortie des processus de l'intervalle $[-A_N, A_N]$, basées sur une approximation plus fine de la densité de transition, sont nécessaires.

Notons toutefois que l'établissement de ce résultat a nécessité de supposer le coefficient de diffusion connu et constant ($\sigma^* = 1$). Ainsi, dans un autre article soumis cette année, j'ai étendu ce résultat au cas où le coefficient de diffusion est supposé inconnu, en utilisant la formule exacte de la densité de transition établie dans Dacunha-Castelle & Florens-Zmirou (1986) et en faisant des hypothèses supplémentaires sur le coefficient de diffusion. J'ai également étudié l'optimalité de la vitesse de convergence du risque d'estimation du drift sur $\mathbb{R}$ et obtenu une vitesse minimax de l'odre de $N^{-\beta/(2\beta+1)}$ sur un espace de type Hölder de paramètre de régularité $\beta \geq 1$.

1.4 Classifieur non-paramétrique de type *plug-in*

Nous proposons un classifieur empirique qui imite le classifieur de Bayes. En effet, nous estimons les probabilités conditionnelles $\pi_i^*(X)$ par les quantités respectives

$$\widehat{\pi}_i(X) = \widehat{\phi}_i(\widehat{\mathbf{F}}(X))$$

avec $\widehat{\mathbf{F}}(X) = \left(\widehat{F}_1(X), \ldots, \widehat{F}_K(X)\right)$, et pour chaque $i \in \mathcal{Y}$, $\widehat{\mathfrak{p}}_i = \frac{1}{N}\sum_{k=1}^N \mathbb{1}_{Y_k=i}$,

$$\widehat{F}_i(X) := \int_0^1 \frac{\widehat{b}_i}{\widehat{\sigma}^2}(X_s)dX_s - \frac{1}{2}\int_0^1 \frac{\widehat{b}_i^2}{\widehat{\sigma}^2}(X_s)ds, \quad \widehat{\phi}_i : (x_1, \ldots, x_K) \mapsto \frac{\widehat{\mathfrak{p}}_i \mathrm{e}^{x_i}}{\sum_{j=1}^K \widehat{\mathfrak{p}}_j \mathrm{e}^{x_j}}.$$

Nous définissons ainsi le classifieur empirique de type *plug-in* $\widehat{g}$ par

$$\widehat{g}(X) = \arg\max_{i \in \mathcal{Y}} \widehat{\pi}_i(X).$$

Nous établissons le résultat ci-dessous qui lie l'excès de risque du classifieur empirique aux risques d'estimation des estimateurs non-paramétriques des fonctions de dérive et du coefficient de diffusion:

$$\mathbb{E}\left[\mathcal{R}(\widehat{g}) - \mathcal{R}(g^*)\right] \leq C\left(\sqrt{\Delta_n} + \frac{1}{\mathfrak{p}_0^*\sqrt{N}} + \mathbb{E}\left[b_{\max}\sigma_0^{-2}\sum_{i=1}^K \|\widehat{b}_i - b_i^*\|_n\right] + \mathbb{E}\left[\sigma_0^{-2}\|\widehat{\sigma}^2 - \sigma^{*2}\|_n\right]\right)$$

où la norme empirique $\|.\|_n$ est donnée pour toute fonction h par

$$\|h\|_n^2 := \mathbb{E}_X\left[\sum_{k=0}^{n-1} h^2(X_{k\Delta_n})\right],$$

avec $\mathbb{E}_X$ l'espérance mathématique de la loi marginale du processus de diffusion X. La consistance du classifieur *plug-in* $\widehat{g}$ est alors déduite de la consistance des estimateurs non-paramétriques des fonctions $\mathbf{b}^*$ et σ^{*2}. Notons toutefois que la consistance des bornes de risque $\mathbb{E}\left[\|\widehat{b}_i - b_i^*\|_n\right]$ n'est pas garantie, puisque chaque estimateur $\widehat{b}_i$ est construit à partir des données appartenant à la classe $Y = i$, et la norme empirique $\|.\|_n$ est définie à partir d'un processus de diffusion X dont la classe Y est inconnue. Ainsi, l'établissement de la consistance de ces bornes de risque nécessite un changement de probabilité nous faisant passer de la norme $\|.\|_n$ à chacune des normes $\|.\|_{n,i}$ donnée pour toute fonction h par

$$\|h\|_{n,i}^2 := \mathbb{E}_{X|Y=i}\left[\sum_{k=0}^{n-1} h^2(X_{k\Delta_n})\right].$$

Nous établissons ensuite une vitesse générale de l'ordre de $N^{-1/5}$, les fonctions $\mathbf{b}^*$ et σ^{*2} étant supposées inconnues. Des vitesses plus rapides sont établies en supposant que le coefficient de diffusion σ^* est connu et constant, et en établissant une approximation plus fine de la densité de transition du processus X dont l'existence est assurée sous des hypothèses de régularité sur les coefficients b_i^*, $i \in \mathcal{Y}$ et σ^*. Ainsi, nous établissons une vitesse de l'ordre de $N^{-\beta/(2\beta+1)}$ (au facteur $\exp(\sqrt{c\log(N)})$ près) sur un espace de Hölder de paramètre de régularité $\beta \geq 1$, lorsque les fonctions de dérive sont supposées bornées. Ce résultat est une extension aux trajectoires de diffusion de la vitesse optimale du même ordre établie dans Audibert *et al.* (2007) dans le cadre de la classification binaire de données vectorielles. Pour le cas des fonctions de dérive non-bornées, nous obtenons une vitesse de l'ordre de $N^{-3\beta/4(2\beta+1)}$, comparable à la vitesse établie dans Gadat *et al.* (2016) dans le cadre de la classification binaire de données vectorielles issues d'une loi de probabilité inconnue dont la densité n'est pas bornée inférieurement sur son support.

Dans une seconde investigation, j'ai établi une vitesse de l'ordre de $N^{-\beta/(2\beta+1)}\exp(\sqrt{c\log(N)})$ en supposant cette fois le coefficient de diffusion inconnu, et les coefficients de dérive pouvant être bornés ou non-bornés, le cas des dérives non-bornées nécessitant une hypothèse supplémentaire sur le modèle de diffusion. En me restreingant au cadre binaire ($K = 2$), j'ai étudié l'optimalité de la vitesse et obtenu une vitesse optimale de l'ordre de $N^{-1/2}$ lorsque $\beta \to \infty$.

1.5 Classifieur non-paramétrique de type ERM

On appelle risque empirique de classification, la fonction $\widehat{R}$ construite à partir de l'échantillon $\mathcal{D}_N$, qui, à tout classifieur $g \in \mathcal{G}$ associe la quantité

$$\widehat{R}(g) = \sum_{j=1}^{N} \mathbb{1}_{g(X^j)\neq Y_j}.$$

Un classifieur de type ERM est un classifieur $\widehat{g}$ défini par

$$\widehat{g} = \arg\min_{g\in\mathcal{G}} \widehat{R}(g).$$

Malheureusement, ce classifieur n'est pas implémentable en pratique, car solution d'un problème de programmation non-convexe (voir Bartlett *et al.* (2006)). Pour pallier ce problème et proposer une procédure de classification pouvant être évaluée en pratique, nous convexifions le problème en remplaçant d'une part, la fonction de coût $(y, y') \mapsto \mathbb{1}_{y\neq y'}$ par une fonction convexe calibrée comme la perte quadratique ou toute autre fonction de perte proposée dans Zhang (2004) ou Bartlett *et al.* (2006), d'autre part, l'ensemble non-convexe des classifieurs $\mathcal{G}$ est remplacé par un espace des fonctions score h définies sur l'ensemble des processus $\mathcal{X}$ et à valeurs dans $\mathbb{R}^K$. Nous considérons ainsi le nouveau

risque empirique $\widehat{R}_2$ qui, à toute fonction score $\mathbf{h} = (h^1, \ldots, h^K)$, associe

$$\widehat{R}_2(\mathbf{h}) := \frac{1}{N} \sum_{j=1}^{N} \sum_{i=1}^{K} \big(Z_i - h^i(X^j)\big)^2,$$

avec pour chaque $i \in \mathcal{Y}$, $\quad Z_i \in \{-1, 1\}$. Ainsi, le nouveau classifieur de type ERM est donné par $\widehat{g} = g_{\widehat{\mathbf{h}}}$ avec

$$\widehat{\mathbf{h}} := \arg\min_{\mathbf{h}} \widehat{R}_2(\mathbf{h}).$$

La consistance du classifieur $\widehat{g}$ est établie avec une vitesse de l'ordre de $N^{-\beta/(2\beta+1)}$ sur un espace de Hölder de régularité $\beta \geq 1$, dans le cas où les fonctions $\mathbf{b}^*$ et σ^{*2} sont supposées inconnues. Notons au passage que ce classifieur apparait ainsi plus performant que le classifieur de type *plug-in* qui, sous les mêmes hypothèses, atteind une vitesse plus lente. En effet, le classifieur de type ERM a l'avantage de reposer directement sur l'optimisation de sa performance, l'établissement de cette vitesse n'étant également pas impacté par le support non compact des coefficients du processus de diffusion. Une vitesse plus rapide de l'ordre de $N^{-4\beta/3(2\beta+1)}$ est obtenue en imposant une hypothèse de marge sur la fonction de regression en classification binaire. Nous proposons enfin un estimateur adaptatif du classifieur basé sur la sélection des dimensions des espaces d'approximation des coefficients de dérive et de diffusion par la minimisation d'une d'un risque empirique pénalisé. Ce travail fait l'objet d'un article soumis cette année 2025.

2 Projet de recherche

Ce projet de recherche s'inscrit dans le cadre l'analyse de données fonctionnelles, et s'articule autour de trois principaux axes. Le premier axe se focalise sur l'apprentissage statistique pour les trajectoires de diffusions, en l'occurence la construction d'un estimateur adaptatif du classifieur de Bayes par la minimiation du risque empirique de classification, et l'extension des résultats obtenus aux cas des processus de diffusion inhomogènes en temps. Le deuxième axe est consacré d'une part, à l'étude des vitesses minimax des estimateurs du carré du coefficient de diffusion sur un intervalle compact pour $N \to \infty$, et sur un intervalle non-compact pour chacun des cas $N = 1$ et $N \to \infty$, et d'autre part, à l'étude des vitesses optimales des procédures de classification proposées dans la thèse sous différentes hypothèses sur le modèle, particulièrement le cas général où les coefficients des processus de diffusions sont supposés inconnus, non constants et dépendant de l'espace. Ce axe se focalisera par la même occasion sur la recherche d'une vitesse plus rapide du classifieur non-paramétrique de type *plug-in* en imposant une hypothèse de marge sur la fonction de régression. Le troisième axe étend les résultats obtenus aux processus de diffusion multidimensionnels, et aux processus de diffusion non-linéaires de type McKean-Vlasov. Enfin, dans un quatrième axe, les procédures de classification construites seront évaluées sur des données réelles, particulièrement des données biologiques.

2.1 Analyse des données fonctionnelles appliquée à la dynamique des populations

Des applications sont prévues en dynamique des populations (Nagai & Mimura (1983), Chabert-Liddell *et al.* (2023)). Un travail de recherche sur le comprtement des animaux à partir de leurs trajectoires est en étude avec Pierre Barbillon et Sophie Donnet, en collaboration avec Masoomeh Taghipoor, Christine Duvaux-Ponter et Mathilde Valenchon. On s'intéresse à une population de chèvres en élevage. Le travail consiste dans un premier temps à suivre le mouvement de chaque chèvre au sein d'un même réseau afin d'en tracer les trajectoires aucours du temps. Dans un deuxième temps, nous proposons, à partir des trajectoires collectées, un modèle statistique qui nous permettra de mieux comprendre leur comportement social et/ou alimentaire. On pourra par exemple, au moyen du clustering adapté aux données fonctionnelles, regrouper les chèvres par classes homogènes selon leur intéraction sociale.

2.2 Poursuite des travaux sur les modèles de diffusions unidimensionnelles

Mes travaux de recherche se sont essentiellement focalisés sur les processus de diffusion continus et homogènes en temps. L'objectif sera d'étendre les résultats obtenus aux processus de diffusion inhomogènes en temps, solutions du modèle de diffusion ci-dessous:

$$dX_t = b^*_Y(t, X_t) + \sigma^*(t, X_t)dW_t, \tag{1}$$

où les coefficients de dérive et de diffusion dépendent aussi du temps. Une autre particularité de la thèse a été de considérer les modèles de diffusion dans lesquels seuls les fonctions de dérive discriminent les classes. Ainsi, une autre extension sera de considérer les modèles de diffusion du type:

$$dX_t = b^*(t, X_t) + \sigma^*_Y(t, X_t)dW_t \tag{2}$$

où cette fois, le coefficient de diffusion dépend de l'étiquette Y, une conséquence immédiate étant l'impossibilité d'utilisation du théorème de Girsanov pour le changement probabilité, étape incontournable lors de l'étude de la consistance et la vitesse des procédures de classification. On précise que dans le modèle (2), les coefficients des processus de diffusion pourront aussi dépendre uniquement du temps (cas des processus gausssiens), ou encore dépendre uniquement de l'espace. Une application immédiate d'un tel modèle est l'étude des risques d'actifs financiers en se basant sur leurs volatilités

respectives, lesquelles sont carcatérisées par le coeffiient de diffusion. On pourra ainsi proposer des procédures de classification qui serviront à prédire le niveau de risque d'un actif financier à partir des données observées.

Nous considérerons aussi les modèles de diffusion plus généraux du type:

$$dX_t = b_Y^*(t, X_t) + \sigma_Y^*(t, X_t)dW_t \tag{3}$$

où les coefficients de dérive et de diffusion diffèrent pour chacune des classes, avec $Y \in \{1, \dots, K\}$, $K \geq 2$. Le modèle de diffusion (3) a la particularité de concentrer les difficultés rencontrées dans les modèles (1) et (2) lors de l'étude de la consistance et des vitesses des procédures de classification. Ce modèle se place également dans un cadre où rien ne lie les classes entre elles contrairement aux modèles précédents, ce qui peut être un atout pour bon nombre d'applications en finance ou en biologie par exemple.

On s'intéressera enfin aux processus de diffusion à saut encore appelés processus de Levy. Ces processus ont des applications intéressantes en finance et en biologie cellulaire (voir Romanczuk *et al.* (2012), Etchegaray (2016)).

Étude des vitesses plus rapides et des vitesses optimales. On s'attèlera dans cette partie à établir d'une part, des vitesses optimales des procédures de classification de types *plug-in* et ERM, et des estimateurs non-paramétriques du coefficients de diffusion proposés dans la thèse, et d'autre part, étudier des vitesses plus rapides des procédures de classification.

Hypothèse de marge - Classifieur de type *plug-in*. Le but de cette partie est de tirer profit d'une hypothèse de marge sur la fonction de regression pour établir une vitesse plus rapide que $N^{-1/2}$ du classifieur non-paramétrique de type *plug-in* pour les trajectoires de diffusions. Ce travail nécessitera sans doute des hypothèses suffisamment fortes sur le modèle de mélange de diffusions, précisément sur les coefficients de dérive et de diffusion du processus solution du modèle. Ce travail sera principalement basé sur les méthodes developpées dans Audibert *et al.* (2007) dans le cadre de la construction d'une règle de classification binaire pour des données vectorielles.

Cas des processus de diffusion bornés. Nous avons jusque là travaillé avec les trajectoires de diffusions non-bornées qui nous ont contraint d'estimer les fonctions de dérive et de diffusion sur la droite réelle, nous retrouvant en particulier avec des données générées par une loi de probabilité dont la densité est non-bornée inférieurement sur son support. L'intérêt de considérer les diffusions bornées est de contourner ce problème et de voir s'il est possible, dans ce cadre, d'établir des vitesses de convergence plus rapides sans nécessairement une hypothèse de marge sur la fonction de régression.

Nous considérons par exemple le modèle de Wright-Fisher suivant

$$dX_t = \theta_Y^* X_t(1 - X_t)dt + \sqrt{X_t(1 - X_t)}dW_t$$

à valeurs dans l'intervalle compact $[0, 1]$, où la fonction de dérive qui discrimine les classes, dépend du paramètre inconnu θ_Y avec $Y \in \mathcal{Y} = \{1, \dots, K\}$ indépendant du mouvement brownien $(W_t)_{t\geq 0}$ et de loi discrète inconnue $(\mathfrak{p}_i^*)_{i\in\mathcal{Y}}$. Il s'agit donc d'un problème paramétrique ne nécessitant plus un changement de probabilité, ni d'approximation de la densité de transition du processus solution de ce modèle de mélange.

L'objectif sera de proposer, à partir d'un échantillon d'apprentissage, des procédures de classification de types *plug-in* et ERM pour les trajectoires de diffusions bornées, et d'en établir des vitesses de convergence.

2.3 Extension aux processus de diffusion multidimensionnels et aux diffusions de type McKean-Vlasov

Dans cette partie, nous considerons des modèles plus complexes avec des diffusions non-linéaires de type McKean-Vlasov d'une part, et les processus de diffusion multidimensionnels d'autre part. Le but principal sera de proposer, pour chaque type de modèle, des estimateurs non-paramétriques des coefficients d'équations différentielles stochastiques, et des procédures de classification binaires ou multi-classes.

Cas des processus de diffusion de type McKean-Vlasov. Un travail commun avec Viet-Chi Tran et Hoàng Van Hà étudie des diffusions non-linéaires de type McKean-Vlasov avec condition initiale aléatoire, les coefficients de dérive et de diffusion dépendant de la loi de la diffusion, et s'exprimant à l'aide des espérances conditionnelles (voir par exemple Sznitman (1991)). Nous travaillons actuellement sur la construction d'estimateurs adaptatifs des moments des solutions statistiques.

Cas des processus de diffusion multidimensionnels. Enfin, nous considérerons les processus de diffusion $X = (X_t)_{t\in[0,T]} = \left(X_t^1, \ldots, X_t^d\right)_{t\in[0,T]}$ de dimension $d \geq 2$, et un modèle de diffusion défini comme suit:

$$dX_t = b_Y^*(X_t)dt + \Sigma^*(X_t)dW_t, \quad t \in [0,T], \quad X_0 = x_0 \in \mathbb{R}^d, \tag{4}$$

où $T \in \mathbb{R}_{+*}$ est l'horizon temporel, $(W_t)_{t\geq 0} = \left(W_t^1, \ldots, W_t^d\right)_{t\geq 0}$ est un mouvement brownien de dimension d, la fonction de dérive $\mathbf{b}_Y^* = \left(b_Y^{*1}, \ldots, b_Y^{*d}\right)$ est supposée inconnue et dépend de l'étiquette $Y \in \{1, \ldots, K\}$, avec $K \geq 2$. On suppose que Y est toujours une variable aléatoire indépendante du mouvement brownien $(W_t)_{t\geq 0}$ et de loi discrète $\mathfrak{p}^*$ inconnue. Enfin, le coefficient de diffusion multidimensionnel $\Sigma^* = \left(\sigma_{i,j}^*\right)_{1\leq i,j\leq d}$ est commun à toutes les classes. On distinguera le cas où Σ^* est connu, puis on considérera un cadre plus général avec Σ^* inconnu.

L'objectif est de construire des procédures de classification non-paramétriques de type *plug-in* et de type ERM (minimisation du risque empirique). Comme les classifieurs de type *plug-in* sont basés sur des estimateurs non-paramétriques des coefficients des processus de diffusion, leur étude entrainera inéluctablement une étude sur l'estimation non-paramétrique de ces fonctions, contribuant ainsi à l'enrichissement d'une littérature déjà existante sur l'inférence statistique des processus de diffusion en grande dimension (voir par exemple Schmisser (2013)).

Recommandations

- Claire Lacour, Université Gustave Eiffel
- Charlotte Dion, Sorbonne Université
- Christophe Denis, Sorbonne Université
- Marc Hoffmann, Université Paris-Dauphine
- Viet-Chi Tran, Université Gustave Eiffel

References

Audibert, J.-Y., Tsybakov, A.-B. *et al.* (2007). Fast learning rates for plug-in classifiers. *The Annals of statistics* **35**, 608–633.

Bartlett, P.-L., Jordan, M.-I. & McAuliffe, J.-D. (2006). Convexity, classification, and risk bounds. *Journal of the American Statistical Association* **101**, 138–156.

Biau, G., Bunea, F. & Wegkamp, M.-H. (2005). Functional classification in hilbert spaces. *IEEE Transactions on Information Theory* **51**, 2163–2172.

Cadre, B. (2013). Supervised classification of diffusion paths. *Mathematical Methods of Statistics* **22**, 213–225.

Chabert-Liddell, S.-C., Bez, N., Gloaguen, P., Donnet, S. & Mahévas, S. (2023). Auto-encoding gps data to reveal individual and collective behaviour. *arXiv preprint arXiv:2312.00456* .

Comte, F. & Genon-Catalot, V. (2020). Nonparametric drift estimation for iid paths of stochastic differential equations. *The Annals of Statistics* **48**, 3336–3365.

Cuevas, A., Febrero, M. & Fraiman, R. (2007). Robust estimation and classification for functional data via projection-based depth notions. *Computational Statistics* **22**, 481–496.

Dacunha-Castelle, D. & Florens-Zmirou, D. (1986). Estimation of the coefficients of a diffusion from discrete observations. *Stochastics: An International Journal of Probability and Stochastic Processes* **19**, 263–284.

Denis, C., Dion-Blanc, C. & Martinez, M. (2020). Consistent procedures for multiclass classification of discrete diffusion paths. *Scandinavian Journal of Statistics* **47**, 516–554.

Denis, C., Dion-Blanc, C. & Martinez, M. (2021). A ridge estimator of the drift from discrete repeated observations of the solutions of a stochastic differential equation. *Bernoulli* .

Etchegaray, C. (2016). Modélisation mathématique et numérique de la migration cellulaire. Ph.D. thesis, Université Paris-Saclay (ComUE).

Gadat, S., Gerchinovitz, S. & Marteau, C. (2020). Optimal functional supervised classification with separation condition. *Bernoulli* **26**, 1797–1831.

Gadat, S., Klein, T. & Marteau, C. (2016). Classification in general finite dimensional spaces with the k-nearest neighbor rule. *The Annals of Statistics* **44**, 982–1009.

Hoffmann, M. (1999). Lp estimation of the diffusion coefficient. *Bernoulli* pp. 447–481.

Lamberton, D. & Lapeyre, B. (2011). *Introduction to stochastic calculus applied to finance.* CRC press.

López-Pintado, S. & Romo, J. (2006). Depth-based classification for functional data. *DIMACS Series in Discrete Mathematics and Theoretical Computer Science* **72**, 103.

Nagai, T. & Mimura, M. (1983). Asymptotic behavior for a nonlinear degenerate diffusion equation in population dynamics. *SIAM Journal on Applied Mathematics* **43**, 449–464.

Ramsay, J.-O. & Silverman, B.-W. (2002). *Applied functional data analysis: methods and case studies.* Springer.

Ramsay, J.-O. & Silverman, B.-W. (2005). *Fitting differential equations to functional data: Principal differential analysis*. Springer.

Romanczuk, P., Bär, M., Ebeling, W., Lindner, B. & Schimansky-Geier, L. (2012). Active brownian particles: From individual to collective stochastic dynamics. *The European Physical Journal Special Topics* **202**, 1–162.

Schmisser, E. (2013). Penalized nonparametric drift estimation for a multidimensional diffusion process. *Statistics* **47**, 61–84.

Sznitman, A.-S. (1991). Topics in propagation of chaos. *Lecture notes in mathematics* pp. 165–251.

Zhang, T. (2004). Statistical behavior and consistency of classification methods based on convex risk minimization. *Annals of Statistics* pp. 56–85.